



EÖTVÖS LORÁND TUDOMÁNYEGYETEM

INFORMATIKAI KAR

PROGRAMOZÁSELMÉLET ÉS SZOFTVERTECHNOLÓGIAI
TANSZÉK

Automatikus zenei hangszerfelismerés többszólamú zenében mély neuronhálók segítségével

Témavezető:

Gombos Gergő

Adjunktus, PhD

Szerző:

Hamrák János

programtervező informatikus MSc

Budapest, 2020

EÖTVÖS LORÁND TUDOMÁNYEGYETEM
INFORMATIKAI KAR

DIPLOMAMUNKA TÉMABEJELENTŐ

Hallgató adatai:

Név: Hamrák János
Neptun kód: KLGCQ1

Képzési adatok:

Szak: programtervező informatikus, mesterképzés (MA/MSc)
Tagozat: Nappali

Belső témavezetővel rendelkezem

Témavezető neve: Gombos Gergő

munkahelyének neve: Eötvös Loránd Tudományegyetem, Információs Rendszerek Tanszék

munkahelyének címe: 1117 Budapest, Pázmány Péter sétány 1/C.

beosztás és iskolai végzettsége: Adjunktus, PhD

A diplomamunka címe: Automatikus zenei hangszerfelismerés többszólamú zenében mély neuronhálók segítségével

A diplomamunka témája:

(A témavezetővel konzultálva adja meg 1/2 - 1 oldal terjedelemben diplomamunka témájának leírását)

Diplomamunkám témája az automatikus zenei hangszerfelismerés többszólamú zenében mély neuronhálók segítségével. Egy alkalmas modell segítségével zenék sokaságát tudjuk felannotálni megfelelő címkékkel. Ezek pedig kereső- és ajánlórendszerek alapját képezik. Fontosnak tartom kiemelni, hogy polifonikus (többszólamú) környezetben foglalkozom a problémával. Korunk zenéjének túlnyomó része rendelkezik ezzel a tulajdonsággal és szeretnék minél jobban az életszerűségekre törekedni. A megvalósítás érdekében első lépésként a zene területéhez kapcsolódó elérhető adathalmazok feltérképezésével, összevetésével foglalkozom. Az általam legalkalmasabbnak talált adathalmaz fog szolgálni munkám inputjaként. Főként az ezen adathalmazra épített hagyományos gépi tanulási, illetve mély neuronhálós modellek elemzése nyújt kiindulási pontot saját modellem elkészítéséhez. Diplomamunkám fő célja egy mély neuronhálós modell tervezése és fejlesztése. Ez a modell egy multi-class, multi-label osztályozást fog megvalósítani. Ez azt jelenti, hogy több osztályba (hangszerek) sorolhatjuk az inputokat (zenék), de emellett egy inputhoz (zene) tartozhat több címke (hangszer) is. A modell fejlesztése python nyelven történik, kiegészítve a mély neuronhálós modellek építésére szolgáló Keras magas szintű API-val.

Budapest, 2019.11.20.

Tartalomjegyzék

1. Bevezetés	3
1.1. Motiváció	4
1.2. A dolgozat felépítése	5
1.3. Kapcsolódó munkák	5
2. Elméleti háttér	7
2.1. Zene és reprezentációi	7
2.1.1. Zene fogalma, tulajdonságai	7
2.1.2. Hang reprezentációk	9
2.1.3. Music Information Retrieval (MIR)	12
2.2. Mesterséges intelligencia	14
2.2.1. Gépi tanulás (machine learning)	15
2.2.2. Mély tanulás (deep learning)	15
3. Adathalmaz	16
3.1. Kiválasztási szempontok	16
3.2. Philharmonia Orchestra	18
3.3. OpenMIC	18
3.3.1. VGGish	19
4. Módszertan	20
4.1. Bemeneti adatok, előfeldolgozás	20
4.1.1. Alternatív reprezentációk kinyerése	20
4.1.2. Adathalmazok normalizálása	21
4.1.3. Osztályok kiegyensúlyozása	21
4.1.4. Tanító-, tesztelő- és validáló halmaz kialakítása	21
4.2. Architektúra	22

4.2.1.	Hagyományos Machine Learning - Modeling Baseline	22
4.2.2.	VGGish Embedding Downstream CNN	23
4.2.3.	Deep CNN	23
4.3.	Megvalósítás	23
5.	Kísérletek, eredmények	24
5.1.	Mérőszámok	24
5.2.	Eredmények	25
5.2.1.	Modeling Baseline	26
5.2.2.	Modeling Baseline alternatív reprezentációkkal	26
5.2.3.	VGGish Embedding Downstream CNN	26
5.2.4.	Deep CNN	26
5.3.	Összehasonlítások	26
5.3.1.	saját próbálkozásaim	26
5.3.2.	Más ismert munkákkal	26
6.	Összegzés, kitekintés	27
	Irodalomjegyzék	28

1. fejezet

Bevezetés

Napjainkban a zenéhez legkönnyebben digitális formában, a világhálón keresztül férhetünk hozzá. Néhány kattintással olyan zenei tartalomszolgáltatókat érhetünk el, melyek széleskörű adatbázissal rendelkeznek. A folyamatosan bővülő adatmennyiség ellenére ezeknek az adatbázisoknak átláthatónak és könnyen kezelhetőnek kell maradniuk, hogy a felhasználókat a kívánt módon tudják kiszolgálni. Ennek érdekében nap mint nap új megoldások születnek zenei információk automatikus kinyerése és feldolgozása céljából. Ezek teszik lehetővé a digitálisan tárolt zenék körében például az osztályozást vagy keresést.

A zenei információk kinyerésének tudományába (Music Information Retrieval, a továbbiakban: "MIR") tartozik a továbbiakban taglalt probléma, az automatikus hangszerfelismerés. Ez egy osztályozási feladat. Célja, hogy a meglévő digitális hanganyag alapján az adott zenéről megállapítsuk, hogy milyen hangszerek szólalnak meg benne. Ezt az információt több célra is fel tudjuk használni, például:

- Későbbi feldolgozásra, további MIR feladatok inputjaként
- Statisztikák készítésére
- Adatbázisban való keresés szűrőfeltételeként
- Egy ajánlórendszer részeként, ahol az aktuális zeneszámot követően például egy hangszerelésében hasonló számot szeretnék ajánlani a felhasználónak.

Az automatikus hangszerfelismerés feladatot több aspektusból lehet megközelíteni, például a bemeneti adatok jellege, reprezentációja, a megvalósított architektúra,

az osztályozás módszere, vagy az osztályok száma alapján. A dolgozatom keretein belül felkutatok néhány létező megoldást, majd ezekre alapozva prezentálom saját megközelítésemet és ennek eredményeit. Az általam bemutatott megoldás egy multi-label osztályozást valósít meg mély neuronhálós rendszer segítségével többszólamú zenében.

1.1. Motiváció

Az ember kognitív képességei segítségével a zenében könnyedén fel tudja ismer-
ni az egyes hangszereket. Ugyanez a feladat a számítógép számára azonban már
sokkal kevésbé triviális. Ennek egyik oka, hogy egy hangszer megszólaltatásának
digitális reprezentációja nagyon változatos lehet. Függ például a hangszíntől, hang-
magasságtól, hangerőtől és előadásmódtól, de a felvétel minőségétől és az esetleges
háttérzajtól is. További nehezítő körülmény a többszólamúság, amikor egy időben
több hangszert is megszólaltatunk, ezzel összemosva az egyszólamú környezetben is
sokváltozós képünket.

A MIR nagyban támaszkodik a mesterséges intelligenciára. A számítógépek szá-
mítási kapacitásának folyamatos növekedése és az elérhető adathalmazok gyarapodá-
sa által pedig egyre nagyobb figyelmet kap a mesterséges intelligencia egy kiemelten
számításigényes részterülete: a mély tanulás. Ezt bizonyítja, hogy az évente meg-
rendezésre kerülő ISMIR (International Society for Music Information Retrieval)
konferencián 2010-ben még csak 2 ([1], [2]) mély tanulással kapcsolatos cikk jelent
meg, de 2015-ben már 6, 2016-ban pedig már 16. [3]

A mély tanulás tehát egy ígéretes módszer lehet a MIR problémák megoldásában,
ideértve az automatikus hangszerfelismerést is. Ezt kihasználva és megoldás életsze-
rűségére törekedve döntöttem úgy, hogy elkezdek kísérletezni mély neuronhálókkal
többszólamú zenében. Célom volt találni egy tanításra alkalmas adathalmazt, azon
pedig tervezni egy olyan mély neuronhálós rendszert, amely a jelenlegi megoldások
pontosságát meghaladja.

1.2. A dolgozat felépítése

Dolgozatomban tehát az eddigi kapcsolódó kutatásokat, illetve saját munkám eredményét dolgozom fel. A következő alfejezetben felsorolom az általam relevánsnak tartott, a State-of-the-Arthoz vezető kutatásokat.

A második fejezetben betekintést adok a téma elméleti hátterébe. Először kifejtem a zenével kapcsolatos főbb fogalmakat, bemutatom fontosabb tulajdonságait, reprezentációit. Kitérek a MIR bemutatására is. Ezután bevezetem a gépi tanulás és a mély tanulás fogalmát.

A harmadik fejezet az adathalmazokról fog szólni. Itt előbb felsorolom az adathalmazok kiválasztásának szempontjait, majd minden felhasznált adathalmaznak ismertetem a főbb jellemzőit.

A negyedik fejezetben a módszertanról ejtek szót. Itt kifejtésre kerülnek az adatok előfeldolgozási módszerei, az általam bemutított mély tanulási architektúrák, illetve ezek megvalósításai.

Az ötödik fejezetben részletezem az általam végzett kísérleteket és ezek eredményeit. Ezeket összevetem egymással, illetve a releváns State-of-the-Art kutatásokkal.

A hatodik fejezetben összegzem a leírtakat, valamint továbbgondolom a kutatásomat, felvázolok néhány ötletet annak jövőjéről.

1.3. Kapcsolódó munkák

Az automatikus hangszerfelismerés témában a korábbi kutatások túlnyomó része a monofónikus, azaz egyhangszeres zenékkal foglalkozik. Martin és Kim [4] mintafelismerési statisztikai technikája 1023 izolált hangjegy és 15 különböző hangszer között a hangszercsaládok felismerésében 90%-os, egyéni hangszerek felismerésében pedig 70%-os pontosságot produkált. Brown [5] a kepsztrális együtthatókat használta fel K-közép klaszterezési módszeréhez. Eronen és Klapuri [6] széleskörű, spektrális és időbeli feature-halmaz segítségével - összesen 43 különböző feature felhasználásával - 81%-os hangszer és 95%-os hangszercsalád pontosságról számolt be. Deng [7] klasszikus zenei hangszerek tekintetében elemezte a különböző, gépi tanulási módszerekben használatos feature összeállításokat. Bhalke [8] tört Fourier-transzformáción alapuló MFCC feature-ök segítségével tervezett CPNN osztályozót mutatott be, amellyel

hangszer családok tekintetében 96.5%-os, hangszerek tekintetében pedig 91.84%-os pontosságot ért el.

Többszólamú környezetbe való átültetéssel foglalkozott Burred tanulmánya [9], aki a többszólamúságot két kísérlettel közelítette meg. Először csak egy-egy hangjegyet kombinált össze többszólamú hangjeggyé. Itt két szimultán hangjegy esetén 73.15%-os, három hangjegyre 55.56%-os, négy hangjegy kombinációjára pedig 55.18%-os pontosságot sikerült elérni. Másik kísérletként hosszabb szekvenciákat kombináltak össze, ekkor két hang esetén 63.68%-os, három hang esetén pedig 56.40%-os pontosságot kaptak.

Eggink és Brown [10] a polifónikus zenékben a hiányzó adat elméletükkel próbálták feltárni az egyes hangszereket. Ennek lényege, hogy felderítették azon idő- és frekvenciabeli részeket a zenén belül, ahol szeparáltan egy hangszer tulajdonságait vélték felfedezni és ezt dolgozták fel. Erre a módszerre épített Giannoulis és Klapuri [11] kutatása is, és hasonló megközelítést alkalmazott Garcia [12] is.

Jiang [13] egy többlépcsős megoldást mutat be. Első lépésben a hangszercsaládot határozták meg, ezzel szűkítve a lehetséges hangszerek halmazát és a változók számát. A pontos hangszer-meghatározás csak ezután következett.

Az előbbi kutatások többnyire hagyományos gépi tanulási megoldásokat alkalmaztak, amelyekhez maguk nyerték ki a különböző bemeneti feature-öket. Humphrey [14] írásában a mély tanulási architektúrákat ismerteti a MIR terület korszerű irányzataként. A témában gyakorlati segítségként szolgál Choi [15] írása, amiben konkrét adatrepresentációkat, mély neuronhálós rétegeket, és mély tanulási technikákat mutat be.

Li [16] a nyers hanganyagot inputként felhasználva egy konvolúciós mély neuronhálós rendszert mutatott be a polifónikus zenében való automatikus hangszerfelismerés kapcsán. Ezt a megoldást aztán összevetette hagyományos gépi tanulási módszerekkel is. A mély neuronhálós rendszer teljesített legjobban. 75.60%-os pontossággal, 68.88%-os felidézéssel, 72.08 mikro F értékkel és 64.33 makro F értékkel. Han [17] szintén egy mély konvolúciós hálót használt, azonban az osztályozás szempontjából máshogyan járt el: a zenékben egy darab domináns hangszert keresett. Bemenetként a zenék spektogramját használta fel, 0.602-es mikro és 0.503-as makro F értéket ért el.

2. fejezet


Elméleti háttér

Ebben a fejezetben a dolgozathoz kapcsolódó fogalmakat és elméleti alapokat mutatom be. Először magának a zenének a releváns tulajdonságairól ejtek szót. Ezután ismertetem a MIR kutatási területet, amelybe dolgozatom is tartozik. Majd végül a mesterséges intelligencián alapuló megoldásokról nyújtok elméleti bevezetőt, érintve a hagyományos gépi tanulás és a mély tanulás módszereit is.

2.1. Zene és reprezentációi

2.1.1. Zene fogalma, tulajdonságai

A zene egy meglehetősen összetett fogalom. Az ember számára a zene megjelenhet például hang formájában, leírhatjuk őket szimbólumok segítségével egy kottában, előfordulhat szöveges formában dalszövegként, képi formában egy albumborító, vagy egy zenész képében, illetve mozdulatokban egy zenei előadás keretében. A teljes zenei élményt ezek kombinációja nyújtja. A zene észlelését befolyásoló tényezőket Schedl [18] a következő kategóriákba sorolta: a zene tartalma (music content), a zene kontextusa (music context), a hallgató kontextusa (user context) és a hallgató tulajdonságai (user properties). [19]




2.1. ábra. A zene észlelését meghatározó tényezők, forrás: [18]

A zenei tartalom fogalma utal azokra a tulajdonságokra, melyek a hangok fizikai jelként való leírása definiál. Ilyen például a ritmus, a hangszín, a dallam, a harmónia, a hangerő, vagy a dalszöveg. Ezzel szemben a zene kontextusa alatt azokat a tényezőket értjük, melyeket nem tudunk közvetlenül a zenéből kinyerni, mégis szorosan kapcsolódik hozzá. Ide tartozik például az előadó hírneve, az albumborító, a művész kulturális- vagy politikai háttértörténete, vagy a zeneéhez készített videoklip. Ami a hallgatóval kapcsolatos aspektusokat illeti, a hallgató kontextusa alatt értjük a dinamikus, gyorsan változó tényezőket. Ide sorolható a hallgató aktuális hangulata, tevékenysége, társadalmi helyzete, tér- és időbeli helye, illetve pszichológiai állapota. Ezzel ellentétben a hallgató tulajdonságai az állandó, vagy csak lassan változó jellemzőit takarja. Ilyen az egyén zenei ízlése, zeneelméleti képzettsége, demográfiai adatai, a hallgatott előadóval kapcsolatos véleménye, vagy a barátai zenei ízlése, véleménye. [19]

Dolgozatomban az észlelést meghatározó tulajdonságok közül a zenei tartalmat fogom felhasználni a hangszerek kinyerése érdekében. A zenei tartalom számítógépes felhasználásához pedig elengedhetetlen, hogy a hangokat megfelelően tudjuk számítógépen ábrázolni.

2.1.2. Hang reprezentációk

A hangok fizikai mivoltukban rezgésekként jelennek meg. A rezgéseket matematikailag olyan folytonos függvényekkel tudjuk leírni, melyek értelmezési tartománya az idő, értékészlete pedig a nyugalmi állapothoz viszonyított pillanatnyi kitérés. Ilyen lehet például egy szinuszgörbe. Ahhoz, hogy a hangokat számítógépen tudjuk tárolni és feldolgozni, ezeket a függvényeket kell ábrázolnunk. Mivel azonban a számítógép számábrázolása véges, ezért a hangokat először digitalizálni kell. Ez azt jelenti, hogy a folytonos függvényeket diszkrét, azaz véges helyen vett és véges értékekkel rendelkező függvényekké alakítjuk. Ez úgy történik, hogy ez eredeti függvényünkéből megadott időközönként mintát veszünk, diszkrét értékre kerekítjük, és ezeket az értékeket összefűzzük. Az így kapott függvény lesz a hangnak az idő függvényében ábrázolt digitális reprezentációja.




2.2. ábra. Tíz másodperces hanganyag hanghullám reprezentációja

A hangok idő függvényében ábrázolt digitális reprezentációja tehát egydimenziós, mivel egy függvénygörbének tekinthetjük. Ezt szokták hívni hullámforma reprezentációnak, illetve nyers hangnak (raw audio) is, ugyanis további reprezentációkká tudjuk transzformálni. A MIR területen megjelenő mély tanulási megoldások jelentős része ezen nyers hangábrázolás helyett inkább a kétdimenziós reprezentációkat alkalmazza bemenetként. Ezt azzal indokolják, hogy a nyers bemeneten való tanítás sikeréhez nagyobb adathalmaz szükséges, mint a kétdimenziós reprezentációkéhoz. [15]

Az említett kétdimenziós reprezentációk Fourier-transzformáción alapszanak. A Fourier-transzformáció nagyon leegyszerűsítve egy olyan függvény, amely bemenetként kap egy idő függvényében ábrázolt jelet és ezt felbontja frekvenciákra [20].

- **Ablakozott Fourier transzformált (STFT):** Gábor Dénes magyar fizikus nevéhez kötődik. A bemeneti jelet egyenlő méretű időszeletekre (ablakokra) osztjuk, majd ezeken alkalmazzuk a Fourier-transzformációt. Ezáltal kapjuk meg a hang spektrumát (spectrogram). [20], [15]



2.3. ábra. Spektrum [21]


- **Mel-frekvenciára transzformált spektrum (Mel-spectrogram):** A mel-spectrogram az előbb említett spektrum Mel skálára való transzformáltja. A Mel skálát egy nemlineáris függvény segítségével kapjuk a frekvenciaskálából. Célja, hogy a skála jobban reprezentálja az ember hallásának tartományait. Tehát az értékek közti különbség a Mel skálán megfeleltethető legyen annak, hogy az ember mennyire különböző magasságúnak hallja ezeket. A frekvencia skálán például sokkal nagyobbnak érezzük az 500Hz és 1000Hz közti különbséget, mint a 7500Hz és 8000Hz közti különbséget. A mel-frekvenciára való konverzió képlete a következő:

$$Mel(f) = 2595 * \ln\left(1 + \frac{f}{700}\right) \quad (2.1)$$

Ahol $Mel(f)$ az adott frekvenciaérték mel-skálán való értéke, f pedig az adott frekvencia érték. A képlet segítségével egymást átfedő frekvencia sávokat alakítunk ki, melyek a mel-skálát tekintve egyenlő távolságra helyezkednek el egymástól, majd a frekvenciasávok energia értékeit egyenként leképezzük mel-skálára. [20], [15]

Léteznek egyéb, hasonló skálák is, mint pl. Bark skála, vagy az hallás pszichológián alapuló ERB. Ezek MIR környezetben még nem kerültek összevetésre,

de beszédfelismerés környezetben nem mutatnak szignifikáns eltérést az egyes skálák eredményei. A Mel skála, illetve a mel-spectrogram használata azonban egy gyakran használt és jól felhasználható reprezentációnak bizonyul MIR környezetben. [15]




2.4. ábra. Melspectrogram reprezentáció [21]

- **Mel-frekvencián vett kepsztrum együtthatók (MFCC):** Az MFCC együtthatókat a melspectrogramon való diszkrét koszinusz-transzformációval kapjuk meg. A képlet a következő:

$$C_i(m) = \sum_{n=0}^{M-1} S_i(n) \cos\left[\pi m \frac{n-0.5}{M}\right], 0 \leq m \leq M \quad (2.2)$$

Ahol M a frekvenciaszeletek száma, $S_i(n)$ az egyes sávokban kiolvasott energia értékek és $C_i(m)$ az i -edik MFCC együttható. Ezzel a mel-spectrogramnál tömörebb reprezentációt kapunk. Ennek hátránya lehet az információvesztés, előnye pedig az apró zajok kiszűrése. [8]



2.5. ábra. MFCC reprezentáció [21]

2.1.3. Music Information Retrieval (MIR)

A bevezetőben már említettem a zenei információk kinyerését (music information retrieval - MIR). Ez egy interdiszciplináris kutatási terület, magában hordozza többek között a zeneelmélet, pszichoakusztika, pszichológia, informatika, jelfeldolgozás és gépi tanulás tudományágakat. Céljára jól utal az elnevezése, zenékből szeretnénk releváns információt kinyerni, és ezeket felhasználni [15]. A felhasználásra szerintem nagyon jó, életszerű példát ad Downie 2003-as cikkének [22] bevezetője, amelyet a következőképp fordíthatunk le:

”Képzeljünk el egy világot, ahol egyszerűen felénekelhetjük egy számítógépnek a dalrészletet, ami már reggeli óta a fejünkben jár. A gép elfogadja a hamis énekünket, kijavítja, és azonnal javaslatot tesz arra, hogy éppen a ”Camptown Races” című számra gondoltunk. Miután mi belehallgatunk a gép által talált számos relevánsnak tartott MP3 fájl egyikébe, elfogadhatjuk a gép javaslatát. Ezután elégedetten elutasíthatjuk a felajánlást, hogy az összes további létező verzióját is felkutassa a dalnak, ide értve a nemrég megjelent olasz rap verziót, vagy a skótdudás duettre írt kottát.” [22]

Figyeljük meg, hogy ez a hétköznapi eset mennyire összetett probléma. A következő feladatok jelennek meg:

- Az emberi éneklés, vagy dúdolás alapján hangfelismerés.
- Hang alapú lekérdezés egy zenei adatbázisban az előbbi bemenettel.
- Hangelemzés, feldolgozás, hogy a hamis hangokat ki tudjuk javítani, az esetleges háttérzajokat eltávolítsuk, illetve ha kell, a dallamból automatikusan kottát generáljunk.
- Hasonlóságon alapuló keresés zenék között, hogy megtaláljuk a kívánt dalt az adatbázisban.
- Zenei feldolgozások detektálása, hogy további verzióit is megtaláljuk egy adott dalnak.

MIR problémák definiálását több szempontból közelíthetjük meg. Choi cikke [15] két tengelyre osztja fel a problémateret: szubjektivitás és eldöntési időmérték. A

szubjektivitás tengelyen léteznek szubjektívebb feladatok, melyekre nincsenek egyértelmű válaszok. Ilyen lehet például a zene műfajának meghatározása. Objektívebb feladatoknak tekinthetjük azokat, melyek eredménye egyértelműen meghatározható, esetleg számszerűsíthető. Ide tartozik a hangszerfelismerés, vagy a tempó észlelés. [15]

A másik tengely, az eldöntési időmérték aszerint sorolja be a feladatokat, hogy mekkora időegységeken értelmezhető egy becslés. Ez egy relatív mérték. Például a dallamfelismerés eldöntési időmértékére azt mondhatjuk, hogy alacsony, mert egy felismert dallam jó eséllyel nem fedi le az egész zenét. Másik kifejezéssel azt mondhatjuk, hogy ez egy időben változó, azaz dinamikus tulajdonság. Ellenben a tempó általában állandó értékű az egész zenében, így a teljes zeneszámot fel tudjuk címkézni egy adott tempóval. Erre azt mondjuk, hogy eldöntési időmértéke relatív magas, azaz ez egy statikus tulajdonsága a zenének.[15]

A hangszerfelismerést tekinthetjük statikus, illetve dinamikus feladatnak is a probléma megközelítésének függvényében. Dinamikus, ha erős címkézést szeretnénk megvalósítani, tehát arra vagyunk kíváncsiak, hogy adott időpillanatban éppen milyen hangszerek szólalnak meg. Gyenge címkézés esetén viszont a feladat statikussá válik. Ebben az esetben az egész zenére vetítve szeretnénk címkéket kapni egyes hangszerek jelenlétével, vagy a többi hangszerrel szembeni dominanciájával kapcsolatban.


A MIR terület főbb részterületei és feladatai Schedl [19] cikkére alapozva a következők:

- Jellemző kinyerés (feature extraction)
 - hangszín leírás pl. [23], [24]
 - kotta- és dallamkinyerés pl. [25], [26], [27]
 - ütem lekövetés, tempó becslés pl. [28], [29], [30]
 - tonalitás becslés pl. [31], [32], [33], [34], [35], [36]
 - struktúrális analízis, szegmentáció pl. [37], [38], [39]
- Hasonlóságon alapuló feladatok
 - hasonlóság mérés pl. [40], [41], [42]

- zenei feldolgozás felismerés pl. [43], [44]
- dúdoláson alapuló lekérdezés pl. [45], [46], [47]
- Osztályozási feladatok
 - érzelem- és hangulatfelismerés pl. [48], [49]
 - műfaj szerinti osztályozás pl. [50], [51]
 - hangszerfelismerés pl. [52]
 - szerző / előadó / énekes felismerés pl. [53]
 - automatikus címkézés pl. [54], [55], [56]
- Alkalmazások
 - hanganyaghoz forrásazonosító készítés (fingerprinting) pl. [57], [58]
 - tartalom alapú lekérdezés pl. [59]
 - zene ajánlás pl. [60], [61], [62]
 - lejátszási lista generálás pl. [63], [64], [65], [66]
 - kottázás pl. [67], [68], [69]
 - dal/előadó sikeresség becslés pl. [70], [71], [72]
 - zene vizualizáció pl. [73], [74], [75], [76], [77]
 - felhasználói felületen való zenei böngészés pl. [78], [79], [80], [81], [82]
 - személyre szabott, alkalmazkodó rendszerek pl. [83], [84], [85], [86]

2.2. Mesterséges intelligencia

A mesterséges intelligencia egy általános fogalom az emberi gondolkodás számítógéppel való reprodukálására történő módszerekre. Ahogy arról a bevezetésben is szót ejtettem, a MIR tudományág gyakran használ mesterséges intelligencián alapuló megoldásokat. A továbbiakban két mesterséges intelligenciát megvalósító módszert mutatok be röviden: elsőként a gépi tanulást, majd a mély tanulást, amely a gépi tanulás egy ágazata és napjaink meghatározó trendje. [87]



2.6. ábra. Egyes fogalmak közti kapcsolat szemléltetve, forrás: [87]

2.2.1. Gépi tanulás (machine learning)

A gépi tanulás tehát a mesterséges intelligencia megvalósításának egy módszere. Lényege, hogy explicit utasításokat tartalmazó program helyett a bemeneti adatokat egy tanító algoritmusnak adjuk át. Ha elég mennyiségű és minőségű adatot szolgáltatunk a tanításhoz, akkor a modellünk

Hagyományos gépi tanulásról beszélünk, amikor

//TODO

Feladatok

- Regresszió
- Osztályozás
- Klaszterezés

Overfitting underfitting
optimization

2.2.2. Mély tanulás (deep learning)

A mély tanulás gyakorlatilag a gépi tanulás egy részhalmaza.

//TODO miben más mint az ML, architektúrák stb

3. fejezet

Adathalmaz

Ebben a fejezetben a munkám kapcsán felkutatott és alkalmazott adathalmazokról lesz szó. Egy deep learning megoldás tervezésének első lépéseként érdemes egy alkalmas kiinduló adathalmazt kiválasztani. Ezt aztán a modell tanítására és tesztelésre használjuk.

3.1. Kiválasztási szempontok

Egy adott MIR probléma felügyelt tanulási módszerrel való megközelítésekor az adathalmazzal szemben alapvetően két nagyon fontos szempontot kell vigyelembe vennünk.

1. **Az adatok jellemzői:** a zenékre vonatkozó szerzői jogok miatt a kutatók általában nem tudnak hozzáférni "valós", mindennapi életben előforduló zenékből álló adathalmazhoz, így a fellelhető adathalmazokat általában mesterségesen, kutatási célra fejlesztik. Emiatt mérlegelnünk kell például a következő jellemzők figyelembe vételével:

- Elérhető számunkra? Ingyenes?
- A nyers hanganyag rendelkezésre áll, vagy csak valamilyen alternatív reprezentáció? Utóbbi esetén mi az pontosan?
- Átestek e valamilyen előfeldolgozáson a minták?
- Milyen minőségűek a felvételek? Zajosak?
- Egyszólamúak, vagy többszólamúak a hangminták?

- Milyen hosszúak a minták? Egy hangjegy, fix hosszúságú (például 10 másodperc), vagy teljes zenék?
- Mennyire szerteágazó az adathalmaz? Az általunk vizsgálni kívánt, vagy egyéb fontos tulajdonsággal kapcsolatban van túlreprezentált, vagy alulreprezentált érték?

2. **A metaadatok jellemzői:** egy adott MIR probléma felügyelt tanulási módszerrel való megközelítéséhez fontos, hogy adathalmazunkhoz rendelkezésre álljanak a tanítani kívánt jellemzők metaadatként, például:

- Hangszerek
- Zene feldolgozásai
- Tempók
- Dallamok
- Stílus besorolások
- Egyéb címkék, metaadatok...

Fontos, hogy ezek jellege is megfeleljen az igényeinknek. Például hogy az címkék egy adott időpontra vonatkoznak, vagy statikus egy bemenetre, vagyis hogy a címkézés erős, vagy gyenge.

A metaadatok fogják meghatározni a lehetséges osztályozási feladat típusát is. Például ha bináris értékekkel rendelkezünk minden bemenet minden címkéjére, azzal egy multi-label osztályozást valósíthatunk meg. Míg ha az egyes bemenetekhez egy címke tartozik (és kettőnél több lehetséges címke közül választhatunk), az egy multi-class osztályozást fog jelenteni.

Egy remek gyűjtőoldalnak bizonyult a Nemzetközi MIR Közösség (International Society of Music Information Retrieval - ISMIR) weboldala. Számos adathalmazhoz biztosít hivatkozást, kulcsszavakban leírja a bennük található adatok és metaadatok jellegét és azt, hogy a hangfájlok csatolva vannak-e az adott adathalmazhoz. [88]

Kísérleteimhez első körben egy egyszerű, könnyen tanítható adathalmazt kerestem (ld. Philharmonia Orchestra). Majd miután ezen megbizonyosodtam a modell működéséről, kísérletet tettem egy reprezentatívabb adathalmazba való átültetésre (ld. OpenMIC).

3.2. Philharmonia Orchestra

Kutatásom első fázisában a Philharmonia Zenekar ingyenesen elérhető hangmin-ta könyvtárát használtam fel. A könyvtárban egyszólamú mintákat találunk, melye-
ket a zenekar tagjai vettek fel és tettek közzé használatra. A minták a főkönyvtáron
belül a bennük megszólaló hangszer nevével megegyező könyvtárban találhatóak. Ez
biztosítja a hangszer címkézés metaadatát.

Egy minta az adott hangszerrel egy hangjegy lejátszását tartalmazza. Mivel a
minták rövidek és tiszták, a hangszerek közti különbségek relatív könnyen felismer-
hetőek. Az adathalmazban összesen 20 hangszer szerepel. Az egyes hangszerek kü-
lönböző mennyiségű mintával vannak jelen, hangszerenként körülbelül 100 és 1000
közti fájl érhető el, összesen 12 992 fájl.

3.3. OpenMIC

A többszólamúság bevezetését kutatásomban az OpenMIC [89] adathalmaz fel-
használásával értem el. Ez szintén egy ingyenesen elérhető adathalmaz, melynek
tartalma 20 000 többszólamú minta 20 különböző hangszert lefedve. A minták 10
másodperc hosszú kivonatok a Free Music Archive-on [90] elérhető zenékből. [89]

Az adathalmaz igen előnyös metaadatok tekintetében. Amellett, hogy az összes
hanganyag elérhető .ogg formátumban, a hangszer címkék egy fájlban elérhetőek.
Minden egyes mintához hangszereként definiált, hogy az adott hangszer megszólal-e
a mintában. Az, hogy hangszerenként külön információnk van a mintákra vonatko-
zóan, lehetőséget ad arra, hogy multi-label osztályozást valósítsunk meg. [89]

A címkézéshez bárki hozzájárulhatott. Nyílt, tömeges folyamat volt. Hátránya,
hogy nem minden minta összes hangszeréhez született egyértelmű címke. A gyakor-
latban egy mintához hangszerenként két változó tartozik: egyik egy bináris maszk
változó, amely arra utal, hogy van-e információ az adott minta vonatkozásában az
adott hangszer jelenlétéről. A másik változóban egy százalékérték található, amely
az adott hangszer előfordulásának valószínűségét mondja meg a címkézést végző
közösség ítéletei alapján. Ez természetesen csak akkor tekinthető relevánsnak, ha a
maszk változóban a vonatkozó érték igaz. Ezáltal a címkézést rugalmasnak tekinthet-

jük, hiszen mi magunk határozhatunk meg egy küszöbértéket a hangszer jelenlétére vonatkozóan. [89]

3.3.1. VGGish

Az OpenMIC adathalmazhoz továbbá csatoltak a nyers hanganyag alternatívájaként egy "VGGish" elnevezésű reprezentációt is, mint felhasználható bemenetet. Ez a reprezentáció a nyers hanganyag feldolgozása egy VGG [91] architektúrán alapuló mély neuronhálón, amely a VGGish elnevezést kapta. Ez a neuronhálós modell egyfajta előfeldolgozást valósít meg számunkra. A belőle kapott reprezentáció 0.96 másodperces, egymást nem átfedő időablakokként egy 128 értéket tartalmazó leíró vektorból áll. Felhasználásával mi egy sekélyebb downstream, vagyis utána illesztett modell használatával érhetünk el kielégítő osztályozási eredményeket. [92]

4. fejezet

Módszertan

Ebben a fejezetben az alkalmazott módszertant mutatom be. Először ismertetem az alkalmazott előfeldolgozási módszereket. Ezután a tanító modellek architektúráját mutatom be. Végül pedig szót ejtek az ismertetett módszerek implementációjáról.

4.1. Bemeneti adatok, előfeldolgozás

Az OpenMIC adathalmazmal két formában kapjuk meg a bemeneti adatokat. Egyrészt elérhetőek a nyers hanganyagok .ogg formátumban. Ezen kívül rendelkezésre állt a VGGish nevű reprezentáció is, amelyről a korábbi 3.3.1 fejezetben írtam. A bemeneti adatokat tanítás előtt azonban néhány előfeldolgozási folyamaton vittem végig részben a megvalósíthatóság, részben pedig a performancianövelés érdekében. Ezekről írok a következő alfejezekben.

4.1.1. Alternatív reprezentációk kinyerése

A .ogg fájlokból beolvasott nyers audioval való tanítás sajnos nem volt lehetséges, mivel ez egy memória szempontjából igen költséges reprezentáció, amihez a hardver eszközöm kapacitása kevésnek bizonyult. Helyette a dolgozat korábbi fejezetében bemutatott melspectogram és MFCC reprezentációkat használtam fel. Mindkét reprezentációt a beolvasott nyers hullámforma reprezentációból nyertem ki az elméleti háttér fejezetben leírt módon.

4.1.2. Adathalmazok normalizálása

Az adatok normalizálása a tanulási folyamat gyorsítására szolgál. A normalizálást úgy érjük el, hogy az adatokat arányosan a 0 és 1 értékek közé transzformáljuk. Erre egy szokásos megoldás:

$$x(i) := (x(i) - x_{\min})(x_{\max} - x_{\min}) \quad (4.1)$$

A normalizált adathalmon a gradiens általában hamarabb csökkenthető, ezért a tanítási folyamat rövidebb lehet. [93]

4.1.3. Osztályok kiegyensúlyozása

Tanító modelleknél gyakori probléma, hogy a tanulni kívánt osztályok egy része alul van reprezentálva. Dolgozatom multi-label osztályozása esetén két osztályról beszélhetünk: igaz (jelen van az adott hangszer) és hamis (nincs jelen az adott hangszer). Mivel sok esetben a hamis értékek jelentős többségben voltak, - egyes hangszeresek esetén az összes adat közel 80%-át is kitette - ezért a modell jó pontosságot tudott elérni csupán "hamis" predikciókkal.

Ezt elkerülendő, három megoldás jöhetett szóba:

- Alulmintavételezés (Undersampling) - a többségi osztályokból véletlenszerűen eltávolítunk annyi elemet, hogy az osztályok kiegyensúlyozottá váljanak.
- Túlmintavételezés (Oversampling) - a kisebbségi osztályok véletlenszerű elemeit duplikáljuk addig, amíg az osztályok kiegyensúlyozottá válnak.
- Adat augmentáció (Data augmentation) - hasonlóan az oversampling technikához a kisebbségi osztály elemeit bővítjük. Ebben az esetben a meglévő elemek transzformálásával mesterségesen hozunk létre új elemeket (pl. képeknél forgatás). [94]

Dolgozatom keretében az undersampling módszert alkalmaztam.

4.1.4. Tanító-, tesztelő- és validáló halmaz kialakítása

Tanító modellek alkalmazásakor fontos, hogy legalább kettő, de inkább három független adathalmazzal rendelkezünk:

- Tanító adathalmaz (Train Set) - ebből a halmazból tanul és ezt a halmazt látja a modellünk.
- Validáló adathalmaz (Validation Set) - a tanítási lépések (epoch-ok) között ezen a tanító halmaztól független adathalmazon kiértékeljük modellünk működését. Ezáltal visszajelzést tudunk adni a tanítási folyamat felé és ha szükséges, változtathatunk a hiperparamétereken. Modellünk tehát ezt a halmazt időnként látja, de nem ebből tanul.
- Teszt adathalmaz (Test Set) - a tanítási folyamat végén ezen a halmazon értékeljük ki modellünk teljesítményét. Modellünk ezt a halmazt a tanítás alatt egyáltalán nem látja és ezáltal nem is tud tanulni belőle. Ezzel a függetlenséggel biztosítjuk a kiértékelés torzítatlanságát. [95]

Bevett szokás, hogy e három halmazt körülbelül 60%-20%-20% arányban osszuk fel a tanító halmaz javára. [95] Dolgozatom során én is ezt az elvet követtem.

4.2. Architektúra

A következő alfejezetekben a különböző tanító modell kísérletek architektúráját mutatom be.

4.2.1. Hagyományos Machine Learning - Modeling Baseline

//TODO felhasznált deep learning architektúra(?)

+ alternatív reprezentációkkal is Az OpenMIC dataset megalkotói bemutattak egy példa modellt, amely egy véletlen erdő osztályozó (Random Forest Classifier) modell. Ez egy hagyományos gépi tanulási modell. Az osztályozó 100 eldöntési fából áll, a maximális mélysége 8,

4.2.2. VGGish Embedding Downstream CNN

4.2.3. Deep CNN

4.3. Megvalósítás

//TODO implementáció részletei

python keras tensorflow numpy scipy librosa

5. fejezet

Kísérletek, eredmények

Lorem ipsum

5.1. Mérőszámok

//TODO: <https://towardsdatascience.com/whats-the-deal-with-accuracy-precision-recall-and-f1-f5d8b4db1021> [96]


hogyan tudjuk megmérni a modell teljesítményét, pontosság, tanítás ideje, stb...


A következő metrikákat vizsgáltuk:

- Pontosság (accuracy) - a modell az adott lépésben a bemeneti adatok hány százalékára adott helyes kimenetet?
- Veszteség (loss) - a veszteségfüggvény eredménye. A modell predikcióinak a valóságtól való eltérését összeadva kapjuk meg.
- Precizitás (precision) -
- Felidézés (recall) -
- F1 érték (F1 score) - Ennek a súlyozott átlaga a mérvadó.

F1 érték hangszerenként, ezek átlaga, legkisebb és legnagyobb közti különbség

5.2. Eredmények





5.2.1. Modeling Baseline

5.2.2. Modeling Baseline alternatív reprezentációkkal

5.2.3. VGGish Embedding Downstream CNN

5.2.4. Deep CNN

5.3. Összehasonlítások

5.3.1. saját próbálkozásaim

5.3.2. Más ismert munkákkal

6. fejezet

Összegzés, kitekintés

Továbbfejlesztési ötletek: //TODO undersampling helyett oversampling vagy data augmentation cnn helyett rnn

Irodalomjegyzék

- [1] Florian Eyben és tsai. “Universal Onset Detection with Bidirectional Long Short-Term Memory Neural Networks.” *Proceedings of the 11th International Society for Music Information Retrieval Conference* (Utrecht, Netherlands). Utrecht, Netherlands: ISMIR, 2010. aug., 589–594. old. DOI: 10.5281/zenodo.1417131. URL: <https://doi.org/10.5281/zenodo.1417131>.
- [2] Philippe Hamel és Douglas Eck. “Learning features from music audio with deep belief networks”. *Proceedings of the 11th International Society for Music Information Retrieval Conference (ISMIR)*. Utrecht, The Netherlands, 2010. aug., 339–344. old.
- [3] Keunwoo Choi és tsai. “A tutorial on deep learning for music information retrieval”. *arXiv preprint arXiv:1709.04396* (2017).
- [4] Keith Dana Martin és Youngmoo E. Kim. “Musical instrument identification: A pattern-recognition approach”. 1998.
- [5] Judith Brown. “Computer Identification of Musical Instruments Using Pattern Recognition With Cepstral Coefficients as Features”. *The Journal of the Acoustical Society of America* 105 (1999. ápr.), 1933–41. old. DOI: 10.1121/1.426728.
- [6] A. Eronen és A. Klapuri. “Musical instrument recognition using cepstral coefficients and temporal features”. *2000 IEEE International Conference on Acoustics, Speech, and Signal Processing. Proceedings (Cat. No.00CH37100)*. 2. köt. 2000, II753–II756 vol.2.
- [7] Jeremiah Deng, Christian Simmermacher és Stephen Crane field. “A Study on Feature Analysis for Musical Instrument Classification”. *IEEE transactions on systems, man, and cybernetics. Part B, Cybernetics : a publication of the*

- IEEE Systems, Man, and Cybernetics Society* 38 (2008. máj.), 429–38. old.
DOI: 10.1109/TSMCB.2007.913394.
- [8] Daulappa Bhalke, C. Rao és D. Bormane. “Automatic musical instrument classification using fractional fourier transform based- MFCC features and counter propagation neural network”. *Journal of Intelligent Information Systems* 46 (2015. máj.). DOI: 10.1007/s10844-015-0360-9.
- [9] Juan José Burred, Axel Roebel és Thomas Sikora. “Dynamic Spectral Envelope Modeling for Timbre Analysis of Musical Instrument Sounds”. *Audio, Speech, and Language Processing, IEEE Transactions on* 18 (2010. ápr.), 663–674. old.
DOI: 10.1109/TASL.2009.2036300.
- [10] J. Eggink és Guy Brown. “A missing feature approach to instrument identification in polyphonic music”. 5. köt. 2003. nov., 49–. old. ISBN: 0-7803-7850-4.
DOI: 10.1109/ICASSP.2003.1200029.
- [11] Dimitrios Giannoulis és Anssi Klapuri. “Musical Instrument Recognition in Polyphonic Audio Using Missing Feature Approach”. *Audio, Speech, and Language Processing, IEEE Transactions on* 21 (2013. szept.), 1805–1817. old.
DOI: 10.1109/TASL.2013.2248720.
- [12] Jayme Barbedo és George Tzanetakis. “Musical Instrument Classification Using Individual Partial”. *Audio, Speech, and Language Processing, IEEE Transactions on* 19 (2011. febr.), 111–122. old. DOI: 10.1109/TASL.2010.2045186.
- [13] Wenxin Jiang és Zbigniew Ras. “Multi-label automatic indexing of music by cascade classifiers”. *Web Intelligence and Agent Systems* 11 (2013. ápr.), 149–170. old. DOI: 10.3233/WIA-130268.
- [14] Eric J. Humphrey, Juan Pablo Bello és Yann LeCun. “Moving Beyond Feature Design: Deep Architectures and Automatic Feature Learning in Music Informatics.” *Proceedings of the 13th International Society for Music Information Retrieval Conference* (Porto, Portugal). Porto, Portugal: ISMIR, 2012. okt., 403–408. old. DOI: 10.5281/zenodo.1415726. URL: <https://doi.org/10.5281/zenodo.1415726>.

- [15] Keunwoo Choi és tsai. “A Tutorial on Deep Learning for Music Information Retrieval”. *CoRR* abs/1709.04396 (2017). arXiv: 1709.04396. URL: <http://arxiv.org/abs/1709.04396>.
- [16] Peter Li, Jiyuan Qian és Tian Wang. “Automatic instrument recognition in polyphonic music using convolutional neural networks”. *arXiv preprint arXiv:1511.05520* (2015).
- [17] Yoonchang Han, Jaehun Kim és Kyogu Lee. “Deep convolutional neural networks for predominant instrument recognition in polyphonic music”. *IEEE/ACM Transactions on Audio, Speech, and Language Processing* 25.1 (2016), 208–221. old.
- [18] Markus Schedl, Arthur Flexer és Julián Urbano. “The Neglected User in Music Information Retrieval Research”. *J. Intell. Inf. Syst.* 41.3 (2013. dec.), 523–539. ISSN: 0925-9902. DOI: 10.1007/s10844-013-0247-6. URL: <https://doi.org/10.1007/s10844-013-0247-6>.
- [19] Markus Schedl, Emilia Gómez és Julián Urbano. “Music Information Retrieval: Recent Developments and Applications”. *Foundations and Trends in Information Retrieval* 8 (2014. jan.), 127–261. old. DOI: 10.1561/15000000042.
- [20] Dalya Gartzman. *Getting to Know the Mel Spectrogram*. URL: <https://towardsdatascience.com/getting-to-know-the-mel-spectrogram-31bca3e2d9d0>. Felkeresve: 2020. 05. 09.
- [21] Brian McFee és tsai. *librosa/librosa: 0.6.3*. 0.6.3. verzió. 2019. febr. DOI: 10.5281/zenodo.2564164. URL: <https://doi.org/10.5281/zenodo.2564164>.
- [22] J. Stephen Downie. “Music information retrieval”. *Annual Review of Information Science and Technology* 37.1 (2003), 295–340. old. DOI: 10.1002/aris.1440370108. eprint: <https://asistdl.onlinelibrary.wiley.com/doi/pdf/10.1002/aris.1440370108>. URL: <https://asistdl.onlinelibrary.wiley.com/doi/abs/10.1002/aris.1440370108>.
- [23] G. Peeters és tsai. “The timbre toolbox: extracting audio descriptors from musical signals”. *Journal of the Acoustical Society of America* 130.5 (2011), 2902–2916. old. DOI: 10.1121/1.3642604. URL: <http://eprints.gla.ac.uk/68491/>.

- [24] Perfecto Herrera, Geoffroy Peeters és Shlomo Dubnov. “Automatic Classification of Musical Instrument Sounds”. *Journal of New Music Research* 32 (2010. aug.). DOI: 10.1076/jnmr.32.1.3.16798.
- [25] Anssi Klapuri és Manuel Davy. *Signal Processing Methods for Music Transcription*. 2006. jan. DOI: 10.1007/0-387-32845-9.
- [26] Justin Salamon és Emilia Gómez. “Melody Extraction from Polyphonic Music Signals using Pitch Contour Characteristics”. *IEEE Transactions on Audio, Speech and Language Processing* 20 (2012), 1759–1770. old. URL: <http://hdl.handle.net/10230/42183>.
- [27] Walter B Hewlett és Eleanor Selfridge-Field. *Melodic similarity: Concepts, procedures, and applications, volume 11*. 1998.
- [28] Juan Bello és tsai. “A Tutorial on Onset Detection in Music Signals”. *Speech and Audio Processing, IEEE Transactions on* 13 (2005. okt.), 1035–1047. old. DOI: 10.1109/TSA.2005.851998.
- [29] F. Gouyon. *Computational Rhythm Description*. VDM Verlag, 2008. ISBN: 978-3836477697.
- [30] Martin F. McKinney és Dirk Moelants. “Extracting the perceptual tempo from music”. *ISMIR*. 2004.
- [31] Gregory H. Wakefield. “Mathematical representation of joint time-chroma distributions”. *Advanced Signal Processing Algorithms, Architectures, and Implementations IX*. Szerk. Franklin T. Luk. 3807. köt. International Society for Optics és Photonics. SPIE, 1999, 637–645. old. DOI: 10.1117/12.367679. URL: <https://doi.org/10.1117/12.367679>.
- [32] Elaine Chew. “Towards a mathematical model of tonality”. 2000.
- [33] Emilia Gómez. “Tonal Description of Polyphonic Audio for Music Content Processing”. *INFORMS J. on Computing* 18.3 (2006. jan.), 294–304. ISSN: 1526-5528. DOI: 10.1287/ijoc.1040.0126. URL: <https://doi.org/10.1287/ijoc.1040.0126>.

- [34] Hélène Papadopoulos és Geoffroy Peeters. “Large-Scale Study of Chord Estimation Algorithms Based on Chroma Representation and HMM”. *2007 International Workshop on Content-Based Multimedia Indexing* (2007), 53–60. old.
- [35] Laurent Oudre, Yves Grenier és Cédric Févotte. “Template-based Chord Recognition : Influence of the Chord Types.” *Proceedings of the 10th International Society for Music Information Retrieval Conference* (Kobe, Japan). Kobe, Japan: ISMIR, 2009. okt., 153–158. old. DOI: 10.5281/zenodo.1414884. URL: <https://doi.org/10.5281/zenodo.1414884>.
- [36] David Temperley. “What’s Key for Key? The Krumhansl-Schmuckler Key-Finding Algorithm Reconsidered”. *Music Perception: An Interdisciplinary Journal* 17.1 (1999), 65–100. old. DOI: 10.2307/40285812. URL: <https://doi.org/10.2307/40285812>.
- [37] Matthew L. Cooper és Jonathan Foote. “Automatic Music Summarization via Similarity Analysis”. *ISMIR*. 2002.
- [38] Geoffroy Peeters, Amaury La Burthe és Xavier Rodet. “Toward Automatic Music Audio Summary Generation from Signal Analysis”. *In Proc. International Conference on Music Information Retrieval*. 2002, 94–100. old.
- [39] Wei Chai. “Semantic Segmentation and Summarization of Music”. *IEEE Signal Processing Magazine* (2006. jan.).
- [40] Dmitry Bogdanov és tsai. “From Low-Level to High-Level: Comparative Study of Music Similarity Measures”. 2009. jan., 453–458. old. DOI: 10.1109/ISM.2009.72.
- [41] Michael A. Casey és tsai. *Content-Based Music Information Retrieval: Current Directions and Future Challenges*. 2008.
- [42] Markus Schedl és tsai. “Exploring the Music Similarity Space on the Web”. *ACM Trans. Inf. Syst.* 29.3 (2011. júl.). ISSN: 1046-8188. DOI: 10.1145/1993036.1993038. URL: <https://doi.org/10.1145/1993036.1993038>.

- [43] Joan Serrà, Emilia Gómez és Perfecto Herrera. “Audio Cover Song Identification and Similarity: Background, Approaches, Evaluation, and Beyond”. *Advances in Music Information Retrieval*. Szerk. Zbigniew W. Raś és Alicja A. Wieczorkowska. Berlin, Heidelberg: Springer Berlin Heidelberg, 2010, 307–332. old. ISBN: 978-3-642-11674-2. DOI: 10.1007/978-3-642-11674-2_14. URL: https://doi.org/10.1007/978-3-642-11674-2_14.
- [44] Thierry Bertin-Mahieux és Daniel Ellis. “Large-scale cover song recognition using the 2D Fourier transform magnitude”. (2012. jan.).
- [45] Naoko Kosugi és tsai. “A practical query-by-humming system for a large music database”. 2000. jan., 333–342. old. DOI: 10.1145/354384.354520.
- [46] Justin Salamon, Joan Serrà és Emilia Gómez. “Tonal representations for music retrieval: From version identification to query-by-humming”. *International Journal of Multimedia Information Retrieval, special issue on Hybrid Music Information Retrieval 2* (2013. márc.), 45–58. old. DOI: 10.1007/s13735-012-0026-0.
- [47] Roger Dannenberg és tsai. “A comparative evaluation of search techniques for query-by-humming using the MUSART testbed”. *JASIST* 58 (2007. márc.), 687–701. old. DOI: 10.1002/asi.20532.
- [48] yi-hsuan Yang és Homer Chen. “Machine Recognition of Music Emotion: A Review”. *ACM Transactions on Intelligent Systems and Technology (TIST)* 3 (2012. máj.). DOI: 10.1145/2168752.2168754.
- [49] Cyril Laurier és tsai. “Indexing music by mood: Design and integration of an automatic content-based annotator”. *Multimedia Tools Appl.* 48 (2010. máj.), 161–184. old. DOI: 10.1007/s11042-009-0360-2.
- [50] George Tzanetakis és Perry Cook. “Musical Genre Classification of Audio Signals”. *IEEE Transactions on Speech and Audio Processing* 10 (2002. jan.), 293–302. old.
- [51] Peter Knees, Elias Pampalk és Gerhard Widmer. “Artist Classification with Web-Based Data.” 2004. jan.

- [52] Perfecto Herrera, Anssi Klapuri és Manuel Davy. “Automatic Classification of Pitched Musical Instrument Sounds”. 2006. jan., 163–200. old. DOI: 10.1007/0-387-32845-9_6.
- [53] Youngmoo Kim és Brian Whitman. “Singer Identification in Popular Music Recordings Using Voice Coding Features”. (2002. szept.).
- [54] Mohamed Sordo. “Semantic annotation of music collections: A computational approach”. Dissz. 2012. jan.
- [55] Emanuele Coviello, Antoni Chan és Gert Lanckriet. “Time Series Models for Semantic Music Annotation”. *Audio, Speech, and Language Processing, IEEE Transactions on* 19 (2011. aug.), 1343–1359. old. DOI: 10.1109/TASL.2010.2090148.
- [56] Riccardo Miotto és Nicola Orio. “A Probabilistic Model to Combine Tags and Acoustic Similarity for Music Retrieval”. *ACM Transactions on Information Systems - TOIS* 30 (2012. máj.), 1–29. old. DOI: 10.1145/2180868.2180870.
- [57] Xinxi Wang, David Rosenblum és Ye Wang. “Context-Aware Mobile Music Recommendation for Daily Activities”. 2012. okt. DOI: 10.1145/2393347.2393368.
- [58] Pedro Cano és tsai. “Audio Fingerprinting: Concepts And Applications”. 2. köt. 2005. szept., 233–245. old. DOI: 10.1007/10966518_17.
- [59] Michael Casey és tsai. “Content-Based Music Information Retrieval: Current Directions and Future Challenges”. *Proceedings of the IEEE* 96 (2008. máj.), 668–696. old. DOI: 10.1109/JPROC.2008.916370.
- [60] Oscar Celma. *Music Recommendation and Discovery - The Long Tail, Long Fail, and Long Play in the Digital Music Space*. 2010. jan. ISBN: 978-3-642-13286-5. DOI: 10.1007/978-3-642-13287-2.
- [61] Yuan Zhang és tsai. “Auralist: Introducing serendipity into music recommendation”. 2012. febr., 13–22. old. DOI: 10.1145/2124295.2124300.
- [62] Marius Kaminskas, Francesco Ricci és Markus Schedl. “Location-aware music recommendation using auto-tagging and hybrid matching”. 2013. okt., 17–24. old. DOI: 10.1145/2507157.2507180.

- [63] Tim Pohle és tsai. ““Reinventing the Wheel”: A Novel Approach to Music Player Interfaces”. *Multimedia, IEEE Transactions on* 9 (2007. máj.), 567 – 575. old. DOI: 10.1109/TMM.2006.887991.
- [64] Gordon Reynolds és tsai. “Towards a Personal Automatic Music Playlist Generation Algorithm: The Need for Contextual Information”. (2007. jan.).
- [65] Elias Pampalk, Tim Pohle és Gerhard Widmer. “Dynamic Playlist Generation Based on Skipping Behavior.” 2005. jan., 634–637. old.
- [66] J.-J Aucouturier és Francois Pachet. “Scaling up music playlist generation”. 26. köt. 2002. febr., 105 –108 vol.1. ISBN: 0-7803-7304-9. DOI: 10.1109/ICME.2002.1035729.
- [67] Dixon, Simon Lui és Gerhard Widmer. “MATCH: A Music Alignment Tool Chest”. 2005. szept.
- [68] Meinard Müller, Henning Mattes és Frank Kurth. “An Efficient Multiscale Approach to Audio Synchronization”. 2006. okt.
- [69] Bernhard Niedermayer és Gerhard Widmer. “A Multi-Pass Algorithm for Accurate Audio-to-Score Alignment”. 2010. dec., 417–422. old.
- [70] Markus Schedl és tsai. “What’s Hot? Estimating Country-specific Artist Popularity.” 2010. jan., 117–122. old.
- [71] Francois Pachet és Pierre Roy. “Hit Song Science Is Not Yet a Science.” 2008. jan., 355–360. old.
- [72] Noam Koenigstein és Yuval Shavitt. “Song Ranking based on Piracy in Peer-to-Peer Networks.” 2009. jan., 633–638. old.
- [73] Meinard Müller és Nanzhu Jiang. “A scape plot representation for visualizing repetitive structures of music recordings”. *Proceedings of the 13th International Society for Music Information Retrieval Conference, ISMIR 2012* (2012. jan.).
- [74] Arpi Mardirossian és Elaine Chew. “Visualizing Music: Tonal Progressions and Distributions.” 2007. jan., 189–194. old.
- [75] Matthew Cooper és tsai. “Visualization in Audio-Based Music Information Retrieval”. *Computer Music Journal* 30 (2006. jún.), 42–62. old. DOI: 10.1162/comj.2006.30.2.42.

- [76] Jonathan Foote. “Visualizing Music and Audio using Self-Similarity”. 1999. jan., 77–80. old. DOI: 10.1145/319463.319472.
- [77] Emilia Gómez és Jordi Bonada. “Tonality visualization of polyphonic audio”. (2005. jan.).
- [78] Sebastian Stober és Andreas Nürnberger. “MusicGalaxy: A Multi-focus Zoomable Interface for Multi-facet Exploration of Music Collections”. 6684. köt. 2010. jún., 273–302. old. DOI: 10.1007/978-3-642-23126-1_18.
- [79] Stefan Leitich és Martin Topf. “Globe of Music - Music Library Visualization Using Geosom.” 2007. jan., 167–170. old.
- [80] Paul Lamere és Douglas Eck. “Using 3D Visualizations to Explore and Discover Music.” 2007. jan., 173–174. old.
- [81] Elias Pampalk és Masataka Goto. “MusicRainbow: A New User Interface to Discover Artists Using Audio-based Similarity and Web-based Labeling.” 2006. jan., 367–370. old.
- [82] Rebecca Stewart és Mark Sandler. “The amblr: A mobile spatial audio music browser”. 2011. júl., 1–6. old. DOI: 10.1109/ICME.2011.6012203.
- [83] Markus Schedl és Dominik Schnitzer. “Hybrid retrieval approaches to geospatial music recommendation”. 2013. júl., 793–796. old. DOI: 10.1145/2484028.2484146.
- [84] Sebastian Stober. “Adaptive Methods for User-Centered Organization of Music Collections”. Dissz. 2011. nov.
- [85] Marius Kaminskas, Francesco Ricci és Markus Schedl. “Location-aware music recommendation using auto-tagging and hybrid matching”. 2013. okt., 17–24. old. DOI: 10.1145/2507157.2507180.
- [86] Linas Baltrunas és tsai. “InCarMusic: Context-Aware Music Recommendations in a Car”. 85. köt. 2011. aug., 89–100. old. DOI: 10.1007/978-3-642-23014-1_8.

- [87] Dr. Michael J. Garbade. *Clearing the Confusion: AI vs Machine Learning vs Deep Learning Differences*. URL: <https://towardsdatascience.com/clearing-the-confusion-ai-vs-machine-learning-vs-deep-learning-differences-fce69b21d5eb>. Felkeresve: 2020. 05. 04.
- [88] ISMIR community. *ISMIR list of datasets*. URL: <http://www.ismir.net/resources/datasets/>. Felkeresve: 2020. 05. 10.
- [89] Eric Humphrey, Simon Durand és Brian McFee. “OpenMIC-2018: An Open Data-set for Multiple Instrument Recognition.” *ISMIR*. 2018, 438–444. old.
- [90] Kirell Benzi és tsai. “FMA: A Dataset For Music Analysis”. *CoRR* abs/1612.01840 (2016). arXiv: 1612.01840. URL: <http://arxiv.org/abs/1612.01840>.
- [91] Karen Simonyan és Andrew Zisserman. “Very deep convolutional networks for large-scale image recognition”. *arXiv preprint arXiv:1409.1556* (2014).
- [92] *VGGish*. URL: <https://github.com/tensorflow/models/tree/master/research/audioset/vggish>. Felkeresve: 2020. 05. 14.
- [93] Yann A. LeCun és tsai. “Efficient BackProp”. *Neural Networks: Tricks of the Trade: Second Edition*. Szerk. Grégoire Montavon, Geneviève B. Orr és Klaus-Robert Müller. Berlin, Heidelberg: Springer Berlin Heidelberg, 2012, 9–48. old. ISBN: 978-3-642-35289-8. DOI: 10.1007/978-3-642-35289-8_3. URL: https://doi.org/10.1007/978-3-642-35289-8_3.
- [94] Tara Boyle. *Dealing with Imbalanced Data*. URL: <https://towardsdatascience.com/methods-for-dealing-with-imbalanced-data-5b761be45a18>. Felkeresve: 2020. 05. 13.
- [95] Tarang Shah. *About Train, Validation and Test Sets in Machine Learning*. URL: <https://towardsdatascience.com/train-validation-and-test-sets-72cb40cba9e7>. Felkeresve: 2020. 05. 13.
- [96] Christopher Riggio. *What’s the deal with Accuracy, Precision, Recall and F1?* URL: <https://towardsdatascience.com/whats-the-deal-with-accuracy-precision-recall-and-f1-f5d8b4db1021>. Felkeresve: 2020. 05. 11.